

Комплексные задания по анализу данных

Разведочный анализ и построение прогнозной модели

Цель выполнения этих заданий – формирование общей схемы построения модели прогнозирования в задачах регрессии и классификации – последовательности типовых действий, которые необходимо выполнить в большинстве задач.

Следует иметь в виду, что предлагаемая схема все же носит учебный характер: в реальных задачах с неподготовленными исходными данными, как правило, требуются дополнительные процедуры (приведение данных к единому формату, выявление и исправление ошибок, обработка выбросов и экстремальных значений, применение дополнительных методов исследования, не рассмотренных в рамках данного курса и т. п.). Количество и содержание этих дополнительных действий определяется особенностями конкретной задачи.

Все методы анализа и программные конструкции, необходимые для выполнения данных заданий, были рассмотрены в учебных материалах предыдущих занятий. В рамках данных заданий требуется применить изученные ранее технологии для выполнения комплексного анализа.

Обратите внимание: каждое конкретное действие выполняется не «для галочки», а для обоснования выбора тех или иных методов/инструментов на последующих этапах исследования. Поэтому по результату каждого действия необходимо заключение – что дает полученный результат в контексте решения общей задачи построения прогнозной модели. Так же и выбор того или иного метода исследования на каком-то этапе должен быть обоснован результатами, полученными на более ранних этапах.

Внимание: серьезное и ответственное отношение к выполнению данных заданий заметно повышает вероятность успешного выполнения итоговой контрольной работы и экзаменационного задания.

Задание 1 (задача регрессии)

В этом задании используется набор данных о продажах недвижимости из файла *house_prices.csv*, который рассматривался в учебном блокноте по теме 5 «Разведочный анализ данных».

При выполнении этого задания можно воспользоваться результатами разведочного анализа из учебного блокнота, однако, для закрепления навыков рекомендуется выполнить ключевые моменты исследования самостоятельно.

Необходимо реализовать следующую последовательность действий.

1. Проверка корректности импорта и первичное знакомство с данными:

- оценка общего объема данных (количества объектов, доступных для построения модели);
- изучение признаков на наличие пропущенных значений, типы данных;
- анализ корректности значений, присутствующих в наборе.

2. Исследование одномерных распределений количественных входных признаков (по заполненным значениям), а также прогнозируемого признака:

- вычисление и анализ описательных статистик, асимметрии и эксцесса;
- визуализация распределений и анализ полученных диаграмм, сопоставление их со значениями полученных ранее числовых характеристик;
- анализ однородности данных (возможное наличие групп в данных, аномальных значений и др. особенностей);
- формирование гипотез о законах распределений признаков и формулирование рекомендаций о применении тех или иных методов в дальнейших исследованиях.

3. Исследование (по заполненным значениям) на наличие связей между каждым из входных количественных признаков и прогнозируемым признаком, а также на наличие связей количественных входных признаков между собой:

- обоснование для каждой пары признаков применения того или иного метода корреляционного анализа;
- применение выбранных методов, анализ полученных результатов; формулирование выводов;
- визуализация парных распределений, соотнесение результатов визуализации с результатами корреляционного анализа;
- формулирование окончательных выводов по анализу зависимостей.

4. Исследование распределений входных категориальных признаков, а также их влияния на прогнозируемую величину:

- визуализация и анализ распределения категорий;
- исследование возможных зависимостей между категориальными признаками на основе таблиц сопряженности; в случае правомерности применения критерия «хи-квадрат» – применение этого критерия и получение выводов о наличии/отсутствии связей, в случае наличия – о

силе связей;

- визуализация возможных зависимостей между каждым из категориальных входных признаков и прогнозируемым признаком (диаграммы «ящик с усами»), анализ полученных диаграмм, формулирование предположений о наличии/отсутствии зависимостей.

5. На основании проведенного исследования

- отбор наиболее значимых входных признаков для построения модели;
- обоснование целесообразности/нецелесообразности построения линейной модели (на исходных либо логарифмированных значениях признаков).

6. При наличии пропусков: для каждого признака, имеющего пропущенные значения, – обоснование выбора метода их обработки и реализация выбранной стратегии:

- определение доли записей с пропусками в общем количестве записей анализируемого набора данных;
- выполнение процедур статистического анализа, необходимых для обоснованного предположения о механизме формирования пропусков (можно ли считать случайным появление пропущенных значений);
- на основании проведенного анализа и априорной информации о природе признака – обоснование стратегии обработки пропущенных значений в рассматриваемом столбце;
- реализация выбранной стратегии.

7. Разбиение набора данных на обучающую и тестовую выборки. Для обучающей выборки

- для каждого количественного входного признака – обоснование выбора метода масштабирования; обучение соответствующих обработчиков;
- для каждого категориального признака – обоснование метода преобразования категорий в числовые значения; обучение соответствующих обработчиков.

8. На подготовленных обучающих данных – создание и обучение модели регрессии (линейной или нелинейной – в соответствии с результатами выполнения п. 5), анализ полученных результатов.

8.1. Для модели линейной регрессии:

- создание модели и обучение ее на подготовленных обучающих данных;
- анализ коэффициентов обученной модели, выявление возможных признаков переобучения.

8.2. Для моделей на основе деревьев решений:

- создание и обучение нескольких одиночных деревьев различной глубины;
- создание и обучение случайного леса;
- визуализация одного из построенных деревьев и интерпретация предикатов разбиения вершин.

8.3. Для моделей любого типа:

- получение прогнозов всех построенных моделей на обучающих данных;
- оценка качества прогнозов на обучающей выборке с использованием метрик MSE , MAE и R^2 , интерпретация всех полученных значений;
- оценка значимости входных признаков.

9. Для тестовой выборки

- предобработка данных с использованием обученных ранее обработчиков (без переобучения их на тестовых данных!);
- получение прогнозов обученных ранее моделей на тестовых данных;
- оценка качества прогнозов на тестовой выборке с использованием метрик MSE , MAE и R^2 , интерпретация всех полученных значений.

10. Оценка качества прогнозирования полученной модели

- сопоставление значений метрик на обучающей и тестовой выборке, формулирование выводов относительно обобщающей способности полученной модели;
- визуализация результатов моделирования в координатах «правильные ответы» – «прогнозы модели» для тестовой выборки; оценка качества прогнозов на основе визуального представления;
- формулирование итоговых выводов о качестве прогнозирования.

11. В случае неудовлетворительного качества полученной модели – анализ возможных причин и выполнение мероприятий по их устранению. Это может быть

- доработка/усовершенствование процедур подготовки данных;
- изменение типа модели (например, если линейная модель оказалась непригодной и предполагаемая причина неудачи – именно в этом, а не в качестве подготовки данных);
- подбор гиперпараметров модели и др.

Задание 2 (задача бинарной классификации)

В этом задании используется набор данных для задачи кредитного скоринга по данным немецких банков (аналогичный набору данных из задания 2 и 3 дополнительных заданий по теме 10 – с тем же описанием признаков).

Необходимо реализовать следующую последовательность действий (в целом, эта схема аналогична представленной в задании 1, но некоторые пункты отражают особенности задачи классификации).

1. Проверка корректности импорта и первичное знакомство с данными:

- оценка общего объема данных (количества объектов, доступных для построения модели);
- изучение признаков на наличие пропущенных значений, типы данных;
- анализ корректности значений, присутствующих в наборе;
- определение числа классов и количества объектов по каждому классу; оценка сбалансированности классов.

2. Исследование одномерных распределений количественных входных признаков (по заполненным значениям):

- вычисление и анализ описательных статистик, асимметрии и эксцесса;
- визуализация распределений и анализ полученных диаграмм, сопоставление их со значениями полученных ранее числовых характеристик;
- анализ однородности данных (возможное наличие групп в данных, аномальных значений и др. особенностей);
- формирование гипотез о законах распределений признаков и формулирование рекомендаций о применении тех или иных методов в дальнейших исследованиях.

3. Исследование (по заполненным значениям) на наличие связей входных признаков между собой, а также между каждым из входных и прогнозируемым признаком:

- обоснование для каждой пары признаков применения того или иного метода корреляционного анализа;
- применение выбранных методов, анализ полученных результатов; формулирование выводов;
- визуализация парных распределений, соотнесение результатов визуализации с результатами корреляционного анализа;
- визуальная оценка влияния каждого из количественных признаков на

прогнозируемый признак: визуализация распределений входных признаков отдельно для каждого из двух значений выходного признака (на одном графике), сопоставление полученных распределений;

- формулирование окончательных выводов по анализу зависимостей.

4. Исследование распределений входных категориальных признаков, а также их влияния на прогнозируемый признак:

- визуализация и анализ распределения категорий;
- исследование возможных зависимостей между входными категориальными признаками на основе таблиц сопряженности; в случае правомерности применения критерия «хи-квадрат» – применение этого критерия и получение выводов о наличии/отсутствии связей, в случае наличия – о силе связей;
- изучение возможных зависимостей между каждым из категориальных входных признаков и прогнозируемым признаком (прогнозируемый признак рассматривать как категориальный);
- формулирование окончательных выводов по анализу зависимостей.

5. На основании проведенного исследования

- отбор наиболее значимых входных признаков для построения модели;
- выбор алгоритмов машинного обучения, пригодных для построения модели (линейный классификатор, логистическая регрессия, модели на основе деревьев решений и т. п.).

6. При наличии пропусков: для каждого признака, имеющего пропущенные значения, – обоснование выбора метода их обработки и реализация выбранной стратегии:

- определение доли записей с пропусками в общем количестве записей анализируемого набора данных;
- выполнение процедур статистического анализа, необходимых для обоснованного предположения о механизме формирования пропусков (можно ли считать случайным появление пропущенных значений);
- на основании проведенного анализа и априорной информации о природе признака – обоснование стратегии обработки пропущенных значений в рассматриваемом столбце;
- реализация выбранной стратегии.

7. Для прогнозируемого признака – обоснование выбора метода преобразования категорий в числовые значения; реализация выбранного метода кодирования.

8. Разбиение набора данных на обучающую и тестовую выборки. Для

обучающей выборки

- для каждого количественного входного признака – обоснование выбора метода масштабирования; обучение соответствующих обработчиков;
- для каждого категориального признака – обоснование метода преобразования категорий в числовые значения; обучение соответствующих обработчиков.

9. На подготовленных обучающих данных – создание и обучение модели классификации (линейной или нелинейной – в соответствии с результатами выполнения п. 5), анализ полученных результатов.

9.1. Для модели линейного классификатора и логистической регрессии:

- создание модели и обучение ее на подготовленных обучающих данных;
- анализ коэффициентов обученной модели, выявление возможных признаков переобучения.

9.2. Для моделей на основе деревьев решений:

- создание и обучение нескольких одиночных деревьев различной глубины; создание и обучение случайного леса;
- визуализация одного из построенных деревьев и интерпретация предикатов разбиения вершин.

9.3. Для моделей любого типа:

- получение прогнозов всех построенных моделей на обучающих данных;
- оценка качества прогнозов на обучающей выборке с использованием метрик *accuracy*, *precision*, *recall* и *F-меры*, интерпретация всех полученных значений;
- оценка значимости входных признаков.

10. Для тестовой выборки

- предобработка данных с использованием обученных ранее обработчиков (без переобучения их на тестовых данных!);
- получение прогнозов обученных ранее моделей на тестовых данных;
- оценка качества прогнозов на тестовой выборке с использованием метрик *accuracy*, *precision*, *recall* и *F-меры*, интерпретация всех полученных значений.

11. Оценка качества прогнозирования полученной модели

- сопоставление значений метрик на обучающей и тестовой выборке, формулирование выводов относительно обобщающей способности

полученной модели;

- для модели логистической регрессии и моделей на основе деревьев решений: построение *ROC*-кривых для обучающей и тестовой выборки; визуальная оценка качества прогноза вероятности принадлежности классу по полученным кривым;
- для модели логистической регрессии и моделей на основе деревьев решений: оценка качества прогноза вероятности принадлежности классу с помощью метрики *AUC-ROC* на обучающей и тестовой выборке; интерпретация полученных результатов;
- формулирование итоговых выводов о качестве прогнозирования.

12. В случае неудовлетворительного качества полученной модели – анализ возможных причин и выполнение мероприятий по их устранению. Это может быть

- доработка/усовершенствование процедур подготовки данных;
- изменение типа модели;
- подбор гиперпараметров модели и др.