Дисциплина: Методы искусственного интеллекта

Инструменты: Python, Pandas, Scikit-learn, Yandex DataLens

ПРАКТИКА №1: РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ (EDA) И БАЗОВОЕ МО

Цели и план занятия

- 1. Провести разведочный анализ (EDA) датасета телеком-оператора.
- 2. Очистить данные от «мусора» (пропуски, аномалии, неверные типы).
- 3. Подготовить признаки (Feature Engineering) для алгоритма.
- 4. Обучить базовую модель классификации и оценить её качество.
- Главный принцип: Garbage In, Garbage Out (Мусор на входе = мусор на выходе).

Что такое EDA и почему это важно?

- EDA (Exploratory Data Analysis) — это этап изучения данных через визуализацию и статистические сводки *до* обучения моделей.
- Правило «Garbage In, Garbage Out» (GIGO): Если на вход модели подать мусор, на выходе получится мусор.
- Инструменты в Python: Pandas (таблицы), Matplotlib/Seaborn (графики).
- No-code альтернатива (Отечественное ПО): Yandex DataLens — для быстрого визуального исследования без написания кода.

Бизнес-задача: Прогноз оттока клиентов (Churn)

- Контекст: Телеком-оператор теряет абонентов.
- Экономика: Удержание существующего клиента в 5-7 раз дешевле, чем привлечение нового.
- Цель ML-модели: По профилю клиента (тариф, стаж, услуги) предсказать вероятность его ухода.
- Датасет: Telco Customer Churn (7043 записи, 21 признак).
- Целевая переменная: Churn (1 — ушел, 0 — остался).

Шаг 1. Первичный осмотр данных (EDA)

- df.head() — визуальная оценка первых строк.
- df.info() — проверка типов данных и поиск пропусков (NaN).
- df.describe() — статистические метрики (среднее, мин, макс, квантили).
- Ловушка в датасете: столбец TotalCharges определяется как объект (string), а не число, из-за пустых строк.

Шаг 2. Очистка данных (Data Cleaning)

- Обработка пропусков:
  - Удаление строк (df.dropna), если пропусков мало.
  - Заполнение (df.fillna) средним или медианным значением.
- Удаление дубликатов: df.drop_duplicates().
- Преобразование типов: Приведение TotalCharges к float64.
- Удаление бесполезных признаков: customerID (уникальный идентификатор не помогает прогнозу).

Шаг 3. Визуализация и поиск инсайтов

- Распределение целевой переменной: есть ли дисбаланс классов?
- Сравнение групп: как отличается MonthlyCharges у ушедших и оставшихся?
- Корреляционная матрица (Heatmap): поиск сильно связанных признаков.
- Инструменты: Seaborn, Matplotlib или No-code решение Yandex DataLens.

Шаг 4. Feature Engineering (Создание признаков)

- Модели машинного обучения понимают только числа.
- Label Encoding: Бинарные признаки (Yes/No, Male/Female) -> 1/0.
- One-Hot Encoding: Категориальные признаки (Тип интернета, Метод оплаты) -> набор бинарных столбцов.
- Инструмент: pd.get_dummies() или ColumnTransformer из sklearn.

Шаг 5. Обучение базовой модели

- 1. Разделение на X (признаки) и y (целевая переменная).
- 2. Разделение выборки: train_test_split (80% обучение, 20% тест).
- 3. Масштабирование: StandardScaler (критически важно для линейных моделей и расстояний).
- 4. Выбор модели: LogisticRegression или DecisionTreeClassifier.

Шаг 6. Оценка качества: почему Accuracy врет?

- Accuracy (Доля верных ответов): Бесполезна при дисбалансе классов (модель может просто всегда предсказывать 0).
- Precision (Точность): Из всех, кого мы назвали «ушедшими», сколько реально ушло?
- Recall (Полнота): Из всех реально «ушедших», сколько мы смогли найти?
- F1-score: Гармоническое среднее Precision и Recall.
- ROC-AUC: Способность модели ранжировать объекты (0.5 = случайность, 1.0 = идеал).

Практическое задание в Jupyter Notebook

- 1. Загрузить датасет и исправить тип данных в TotalCharges.
- 2. Построить countplot для Churn и оценить дисбаланс.
- 3. Закодировать категориальные признаки (Label + One-Hot).
- 4. Разделить данные, отмасштабировать и обучить LogisticRegression.
- 5. Вывести classification_report и матрицу ошибок (Confusion Matrix).
- 6. Рассчитать метрику ROC-AUC.

Задания со звёздочкой

- 1. Заменить базовую модель на ансамбль: Random Forest или CatBoost.
- 2. Сравнить метрики (F1, ROC-AUC). Стало ли лучше?
- 3. Построить график важности признаков (feature_importances_). Какой фактор главный?
- 4. (Опционально) Загрузить исходный CSV в Yandex DataLens и собрать дашборд без кода.