Эссе: LLM + RAG в работе инженера по метрологии и АСУ ТП

Дисциплина: Методы искусственного интеллекта I · **Тема:** Лекция 4 (NLP и генеративный ИИ) **Автор:** Макеев Глеб · **Дата:** 04.11.2026

Задача

В моей профессии — инженер по метрологии и АСУ ТП на объектах с системами измерений количества и показателей качества нефти (СИКН) — значительная часть времени уходит не на работу с железом, а на поиск ответа в документах. Нужно быстро найти: какой межповерочный интервал у конкретного преобразователя расхода, какую погрешность допускает методика измерений, что именно требует ГОСТ при оформлении свидетельства о поверке, чем отличается порядок ввода СИКН в эксплуатацию от порядка её аттестации. Ответы «размазаны» по десяткам файлов: федеральный закон, ГОСТы, методики измерений, руководства по эксплуатации, паспорта средств измерений, внутренние регламенты предприятия и переписка с поставщиками.

LLM + RAG решает именно эту задачу: ассистент получает вопрос на естественном языке, находит в корпоративной базе знаний три-пять релевантных фрагментов и формулирует ответ со ссылками на источники. В отличие от «голой» модели, RAG не выдумывает: ответ строится только на документах, а ссылка на фрагмент позволяет инженеру проверить цитату за десять секунд. Это критично в метрологии, где неверная цифра — это не «неточность формулировки», а некорректный результат измерений и спор с надзорным органом.

Облачный API или on-premise

Ключевой вопрос — где считать. Для нашей предметной области решающим является не стоимость токена, а **контур обращения данных**.

Критерий	Облачный API	On-premise
Данные	уходят внешнему провайдеру	не покидают контур предприятия
Старт	часы, оплата по факту	недели: сервер или GPU, обслуживание
Качество модели	лучшее доступное	ограничено железом
Сеть	нужен интернет, на промплощадке часто изолированный контур	работает в закрытом сегменте
Стоимость при больших объёмах	растёт с числом запросов	фиксированные CAPEX/OPEX

Мой выбор — гибридная схема с on-premise акцентом. Векторная база и эмбеддинги размещаются внутри контура: паспорта средств измерений, схемы СИКН, внутренние регламенты и переписка не должны покидать предприятие. Генерация ответа — переключаемая: локальная модель для запросов, затрагивающих конфиденциальные документы, и облачный API для «публичной» части базы (ГОСТы, федеральные нормы), где качество ответа важнее режима. Такое разделение даёт главное — воспроизводимость и проверяемость: инженер всегда видит, на каком фрагменте построен ответ, а администратор — какие модели и где использовались.

Облако «в чистом виде» я бы допустил только для внутренней справочной системы без реальных данных объектов. Полный on-premise с локальной LLM — следующий шаг: сегодня качество русскоязычных локальных моделей достаточное для извлечения фактов по контексту, но требует GPU и сопровождения, что для одного инженера избыточно.

Вывод

Для моей профессии LLM + RAG — не «модная надстройка», а инструмент, снимающий рутину поиска по нормативной документации и снижающий риск ошибки из-за устаревшей или неверно понятой редакции документа. Оптимальная архитектура — RAG-контур с локальным хранением документов и переключаемой моделью генерации: конфиденциальность внутри, качество ответа — снаружи.